ANALISIS KOMPARATIF MODEL TRANSFORMER UNTUK PREDIKSI PENJUALAN EKSPOR MULTIVARIAT DENGAN STUDI KASUS DATA SAP PERUSAHAAN XYZ

PROPOSAL PENELITIAN

DYAH AYU GOLDY CAHYASTUTI

41522120005

PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS ILMU KOMPUTER
UNIVERSITAS MERCU BUANA
JAKARTA
2026

ANALISIS KOMPARATIF MODEL TRANSFORMER UNTUK PREDIKSI PENJUALAN EKSPOR MULTIVARIAT DENGAN STUDI KASUS DATA SAP PERUSAHAAN XYZ

PROPOSAL PENELITIAN

DYAH AYU GOLDY CAHYASTUTI

41522120005

Diajukan sebagai salah satu syarat untuk memperoleh gelar sarjana

PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS ILMU KOMPUTER
UNIVERSITAS MERCU BUANA
JAKARTA

2026

HALAMAN PERNYATAAN KARYA SENDIRI

Saya yang bertanda tangan di bawah ini:

Nama	:	Dyah Ayu Goldy Cahyastuti
NIM	:	41522120005
Program Studi	:	Teknik Informatika
Judul Proposal Penelitian	:	Analisis Komparatif Model Transformer untuk Prediksi Penjualan Ekspor Multivariat dengan Studi Kasus Data SAP Perusahaan XYZ

Menyatakan bahwa Laporan Skripsi ini adalah hasil karya saya sendiri dan bukan plagiat, serta semua sumber baik yang dikutip maupun dirujuk telah saya nyatakan dengan benar. Apabila ternyata ditemukan di dalam Proposal Penelitian saya terdapat unsur plagiat, maka saya siap mendapatkan sanksi akademis yang berlaku di Universitas Mercu Buana.

Tangerang, 07 Agustus 2026



Dyah Ayu Goldy Cahyastuti

HALAMAN PERSETUJUAN

Yang bertanda tangan dibawah ini menyatakan bahwa proposal tugas akhir dari mahasiswa:

Nama	:	Dyah Ayu Goldy Cahyastuti
NIM	:	41522120005
Program Studi	:	Teknik Informatika
Judul Proposal Penelitian	:	Analisis Komparatif Model Transformer untuk Prediksi Penjualan Ekspor Multivariat dengan Studi Kasus Data SAP Perusahaan XYZ

Tangerang, 07 Agustus 2026

Disetujui dan diterima untuk diseminarkan,

Dosen Pembimbing MPTI	Dosen Pengampu MPTI
	
Dr. Hadi Santoso, S.Kom., M.Kom	Wawan Ridwan, ST, MT
NIDN : 0225067701	NIDN : 0307098502

KATA PENGANTAR

Puji syukur kehadirat Tuhan yang Maha Esa, atas segala rahmat dan ridha-Nya sehingga penulis dapat menyelesaikan proposal penelitian yang merupakan salah satu persyaratan kelulusan Program Studi Strata Satu (S1) pada jurusan Teknik Informatika, Universitas Mercu Buana.

Penulis menyadari bahwa proposal penelitian ini masih jauh dari sempurna, karena kesempurnaan sejatinya hanya milik Tuhan yang Maha Esa. Oleh karena itu, saran dan masukan yang membangun senantiasa penulis terima dengan senang hati. Serta berkat dukungan, motivasi, bantuan, bimbingan, dan doa dari banyak pihak, penulis mengucapkan terima kasih kepada:

1. Bapak Prof. Dr. Andi Adriansyah, M.Eng. selaku Rektor Universitas Mercu Buana.
2. Bapak Dr. Bambang Jokonowo, S.Si., MTI selaku Dekan Fakultas Ilmu Komputer.
3. Bapak Dr. Hadi Santoso, S.Kom., M.Kom. selaku Ketua Program Studi Teknik Informatika Universitas Mercu Buana dan juga sebagai Dosen Pembimbing yang memberikan pengarahan, motivasi, menyediakan waktu, tenaga dan pikiran selama pembuatan proposal penelitian.
4. Bapak Wawan Ridwan, ST, MT selaku Dosen Capstone Project yang telah memberikan pengarahan, motivasi, selama pembuatan proposal penelitian.
5. Kedua Orang Tua saya yang selalu mensupport dan mendukung saya selama menjalani masa studi sebagai mahasiswa Universitas Mercu Buana.
6. Semua teman kuliah yang selalu berbagi informasi dan memberikan dukungan dalam bentuk yang berbeda-beda.

Akhir kata, penulis berharap semoga Tuhan yang Maha Esa membalas kebaikan dan selalu mencurahkan rahmat, hidayah, serta panjang umur kepada kita semua, aamiin. Terima Kasih.

Tangerang, ……..2026

ABSTRAK

Nama	:	Dyah Ayu Goldy Cahyastuti
NIM	:	41522120005
Program Studi	:	Teknik Informatika
Judul Proposal Penelitian	:	Analisis Komparatif Model Transformer untuk Prediksi Penjualan Expor Multivariat Dengan Studi Kasus Data SAP Perusahaan XYZ
Dosen Pembimbing	:	Dr. Hadi Santoso, S.Kom., M.Kom

Peramalan penjualan merupakan salah satu aspek penting dalam mendukung pengambilan keputusan pada perusahaan manufaktur, khususnya dalam perencanaan produksi, pengelolaan persediaan, dan distribusi barang. Perusahaan telah memiliki data historis penjualan yang tersimpan dalam sistem Enterprise Resource Planning (ERP) SAP selama tiga tahun, namun pemanfaatannya untuk menghasilkan prediksi penjualan yang akurat masih belum optimal. Di sisi lain, perkembangan arsitektur Transformer menunjukkan kemampuan yang lebih baik dibandingkan model berbasis rekuren dalam menangkap hubungan jangka panjang pada data deret waktu (*time series*). Penelitian ini bertujuan untuk mengimplementasikan dan membandingkan tiga arsitektur Transformer, yaitu MOEBS-Transformer, N-Space Transformer, dan Temporal Fusion Transformer (TFT) dalam melakukan peramalan penjualan berbasis data historis SAP. Penelitian menggunakan pendekatan kuantitatif dengan metode eksperimen komparatif terhadap data penjualan multivariat yang terdiri atas variabel kuantitas penjualan, harga, merek (*brand*), negara tujuan, serta tanggal transaksi. Tahapan penelitian meliputi *data preprocessing*, *exploratory data analysis*, *feature engineering*, pembentukan *sliding window*, pelatihan model, serta evaluasi menggunakan metrik Mean Absolute Error (MAE), Root Mean Square Error (RMSE), Mean Absolute Percentage Error (MAPE), Symmetric Mean Absolute Percentage Error (SMAPE), dan Coefficient of Determination (R^2). Selain itu, penelitian juga mengevaluasi efektivitas mekanisme *self-attention*, kemampuan integrasi fitur kontekstual, serta efisiensi komputasi dari masing-masing model. Penelitian ini diharapkan dapat menghasilkan rekomendasi arsitektur Transformer yang paling sesuai untuk data penjualan berbasis SAP serta memberikan kontribusi dalam pengembangan metode *sales forecasting* berbasis *Deep Learning* pada lingkungan industri manufaktur.

Kata kunci: Sales Forecasting, Transformer, Temporal Fusion Transformer, Time Series, SAP ERP.

ABSTRACT

Nama	:	Dyah Ayu Goldy Cahyastuti
NIM	:	41522120005
Program Studi	:	Teknik Informatika
Judul Proposal Penelitian	:	Comparative Analysis of Transformer Models for Multivariate Export Sales Prediction Based on SAP Historical Data at Company XYZ
Dosen Pembimbing	:	Dr. Hadi Santoso, S.Kom., M.Kom

Sales forecasting is an essential process in supporting decision-making within manufacturing companies, particularly for production planning, inventory management, and product distribution. The company has accumulated three years of historical sales data stored in an Enterprise Resource Planning (ERP) SAP system; however, its utilization for accurate sales prediction remains limited. Meanwhile, recent advances in Transformer-based architectures have demonstrated superior capability over recurrent models in capturing long-term dependencies within time-series data. Therefore, this study aims to implement and compare three Transformer architectures, namely MOEBS-Transformer, N-Space Transformer, and Temporal Fusion Transformer (TFT) for sales forecasting using historical SAP sales data. This research employs a quantitative approach using a comparative experimental method on multivariate sales data consisting of sales quantity, product price, brand, destination country, and transaction date. The research stages include data preprocessing, exploratory data analysis, feature engineering, sliding-window generation, model training, and evaluation using Mean Absolute Error (MAE), Root Mean Square Error (RMSE), Mean Absolute Percentage Error (MAPE), Symmetric Mean Absolute Percentage Error (SMAPE), and the Coefficient of Determination (R^2). In addition, the study evaluates the effectiveness of the self-attention mechanism, contextual feature integration, and computational efficiency of each model. The expected outcome of this research is to identify the most suitable Transformer architecture for SAP-based sales forecasting and to contribute to the development of Deep Learning-based forecasting methods in manufacturing industries.

Keywords: *Sales Forecasting, Transformer, Temporal Fusion Transformer, Time Series, SAP ERP.*

DAFTAR ISI

HALAMAN PERNYATAAN KARYA SENDIRI 2
HALAMAN PERSETUJUAN 3
KATA PENGANTAR 4
ABSTRAK 5
ABSTRACT 6
DAFTAR ISI 7
DAFTAR TABEL 9
DAFTAR GAMBAR 10
BAB I PENDAHULUAN 1
1.1 Latar Belakang 1
1.2 Perumusan Masalah 3
1.3 Tujuan Penelitian 3
1.4 Manfaat Penelitian 3
1. Manfaat Bagi Ilmu Pengetahuan 3
2. Manfaat Bagi Perusahaan 4
1.5 Batasan Penelitian 4
BAB II TINJAUAN PUSTAKA 6
2.1 Teori Utama 6
2.1.1 Forecasting 6
2.1.2 Arsitektur Transformer dan Mekanisme Self-Attention 7
2.1.3 MoEBS Transformer 10
2.1.4 N-Space Transformer 12
2.1.5 Temporal Fusion Transformer (TFT) 15
2.2 Teori Pendukung 16
2.2.1 Multivariate Time Series Forecasting 16
2.2.2 Recurrent Neural Network, LSTM, dan GRU sebagai Baseline 16
2.2.3 Metrik Evaluasi Model Peramalan 17
2.2.4 Pengambilan Keputusan Berbasis Data (Data-Driven Decision Making) 17
2.3 Penelitian Terdahulu 18
2.4 Gap Penelitian 21
BAB III METODE PENELITIAN 23
3.1 Pendekatan Penelitian 23
3.2 Desain Penelitian 23
3.3 Subjek Penelitian 25
3.4 Instrumen Penelitian 26
3.5 Teknik Pengumpulan Data 27

3.6 Analisis Data 27
3.6.1 Data Preprocessing 27
3.6.2 Feature Engineering & Sliding Window 28
3.6.3 Pembagian Data 28
3.6.4 Implementasi dan Pelatihan Model 29
3.7 Prosedur Penelitian 29
3.8 Evaluasi Hasil Penelitian 30
DAFTAR PUSTAKA 32
LAMPIRAN 34

DAFTAR TABEL

Tabel 2.1 Penelitian Terkait 8

DAFTAR GAMBAR

Gambar 3.1 Alur MPTI 18

DAFTAR LAMPIRAN

Lampiran 1 Kartu Asistensi 34

BAB I PENDAHULUAN

1.1 Latar Belakang

Transformasi digital mendorong berbagai perusahaan dalam memanfaatkan data sebagai aset strategis dalam mengambil keputusan. Dalam *data-driven decision making,* perusahaan tidak hanya mengandalkan pengalaman atau intuisi, tetapi memanfaatkan data historis dalam menghasilkan informasi prediksi yang dapat meningkatkan efisiensi operasional, mengurangi risiko bisnis serta meningkatkan daya saing (Elgendy 2022). Pergeseran ini juga didorong oleh perkembangan kecerdasan buatan yang memungkinkan organisasi mengkombinasikan kemampuan analitis mesin dengan penilaian manusia untuk menghasilkan keputusan yang lebih adaptif terhadap dinamika pasar (Rajagopal 2022). Salah satu implementasi yang berdampak besar terhadap aktivitas bisnis adalah prediksi penjualan (*sales forecasting*), karena hasil prediksinya menjadi dasar dalam perencanaan produksi, pengendalian persediaan, distribusi barang, hingga penyusunan strategi pemasaran.

Perusahaan manufaktur yang menjadi objek penelitian sudah menerapkan sistem SAP (*system application and processing)*. SAP menjadi media pencatatan transaksi selama 3 tahun dengan menghasilkan data transaksi *multivariat* yang mencangkup atribut tanggal, transaksi, jumlah penjualan, harga, negara tujuan, musim, merek hingga kode produk. Namun pemanfaatan data tersebut masih dalam tahap laporan operasional dan evaluasi periode sebelumnya, sementara perencanaan produksi dan persediaan masih banyak tergantung pada estimasi *pre-order* yang diajukan oleh pelanggan. Pendekatan ini masih memiliki keterbatasan dalam mengantisipasi perubahan pola akibat permintaan musim, negara tujuan, karakteristik produk, maupun fluktuasi harga sehingga mengakibatkan *overstock* atau *overlimit,* peningkatan biaya, penyimpanan dan keterlambatan pemenuhan permintaan pelanggan.

Model berbasis *Recurrent Neural Network* (RNN), *Long Short-Term Memory* (LSTM), dan *Gated Recurrent Unit* (GRU) sebelumnya banyak digunakan peramalan deret waktu, tetapi memiliki keterbatasan dalam menangkap ketergantungan jangka panjang, proses pelatihan yang bersifat sekuensial

sehingga kurang efisien pada data skala besar, serta rentan terhadap *vanishing gradient.* Arsitektur Transformer dikembangkan untuk mengatasi keterbatasan tersebut melalui mekanisme *self-attention* yang mempelajari hubungan antar data secara paralel, dan terbukti unggul dibandingkan model rekuren pada berbagai domain deret waktu, seperti prediksi beban listrik jangka pendek (Zhao n.d.) indeks pasar saham (Wang 2022) dan pasar keuangan multi model (Kehinde 2023). Meskipun demikian, keunggulan Transformer tidak bersifat mutlak dan sangat bergantung pada data serta strategi prediksi yang digunakan sehingga arsitektur yang lebih sederhana dapat dibandingkan agar penelitian tidak bias terhadap satu arsitektur tertentu (Dai 2025; Zeng 2017)

Berdasarkan kesenjangan tersebut, penelitian ini mengusulkan evaluasi dan perbandingan tiga arsitektur Transformer yang saling melengkapi. MoEBS-Transformer mengoptimalkan hyperparameter model melalui algoritma Multiple Objectives Escaping Bird Search, yang pada studi aslinya diterapkan untuk prediksi harga saham dan terbukti meningkatkan akurasi serta stabilitas prediksi dibandingkan metode optimasi konvensional (Wei 2025). N-Space Transformer memperkuat representasi data multivariat melalui transformasi ruang fitur (N-space transformation) dan modul kontekstual, yang pada studi aslinya diterapkan untuk peramalan beban listrik dan terbukti unggul dibandingkan model Seq2Seq berbasis RNN (Heureux n.d.). Sementara itu, Temporal Fusion Transformer (TFT) menyediakan interpretabilitas melalui *Variable Selection Network* yang mengintegrasikan metadata statis dan dinamis sekaligus mengidentifikasi kontribusi masing-masing variabel terhadap hasil prediksi, sebagaimana ditunjukkan pada penerapannya untuk prediksi harga saham (Hu 2021). Ketiga arsitektur ini belum pernah diterapkan maupun dibandingkan secara langsung pada domain peramalan penjualan ekspor berbasis data ERP SAP, sehingga penelitian ini diharapkan memberikan kontribusi praktis berupa rekomendasi arsitektur yang paling sesuai untuk mendukung perencanaan penjualan dan persediaan perusahaan, serta kontribusi akademik berupa analisis komparatif ketiga arsitektur tersebut pada data multivariat yang belum banyak dikaji dalam literatur (Eglite and Birzniece 2022).

1.2 Perumusan Masalah

1. Bagaimana implementasi arsitektur **MoEBS-Transformer**, **N-Space Transformer**, dan **Temporal Fusion Transformer (TFT)** pada data historis penjualan ekspor?
2. Bagaimana perbandingan performa ketiga model tersebut berdasarkan metrik akurasi **MAE, RMSE, MAPE, SMAPE**, dan R^2
3. Bagaimana efisiensi komputasi dalam mendukung pengambilan keputusan penjualan perusahaan?

1.3 Tujuan Penelitian

Tujuan dari implementasi penulisan laporan tugas akhir yang baik dan benar di Penelitian ini bertujuan untuk:

1. Mengimplementasikan model **MoEBS-Transformer**, **N-Space Transformer**, dan **Temporal Fusion Transformer (TFT)** pada proses prediksi penjualan perusahaan.
2. Membandingkan performa ketiga model menggunakan metrik evaluasi MAE, RMSE, MAPE, SMAPE, dan R^2.
3. Menentukan model Transformer yang paling sesuai untuk diterapkan pada data penjualan ekspor berbasis SAP.

1.4 Manfaat Penelitian

1. Manfaat Bagi Ilmu Pengetahuan

Penelitian ini diharapkan dapat memberikan kontribusi terhadap pengembangan ilmu pengetahuan, khususnya pada Time Series Forecasting dengan membandingkan tiga arsitektur Transformer, yaitu MoEBS-Transformer, N-Space Transformer, dan Temporal Fusion Transformer (TFT) dalam melakukan prediksi penjualan berbasis data historis SAP. Hasil penelitian diharapkan dapat memperkaya referensi mengenai penerapan model Transformer pada data multivariate time series, terutama pada domain penjualan ekspor yang masih relatif sedikit dibahas dibandingkan penelitian pada bidang energi, kelistrikan, maupun pasar saham.

2. Manfaat Bagi Perusahaan

Penelitian ini diharapkan dapat menjadi bahan pertimbangan bagi perusahaan dalam menentukan model forecasting yang mampu memprediksi penjualan secara lebih akurat berdasarkan data historis SAP. Hasil prediksi tersebut diharapkan dapat membantu perusahaan dalam:

1. menyusun perencanaan produksi secara lebih tepat;
2. mengoptimalkan pengelolaan persediaan (*inventory planning*);
3. mengurangi risiko **overstock** maupun **stockout**;
4. mendukung proses pengambilan keputusan berdasarkan data (*data-driven decision making*);
5. meningkatkan efisiensi distribusi dan pemenuhan permintaan pelanggan.

1.5 Batasan Penelitian

Agar penelitian memiliki ruang lingkup yang jelas dan terarah, maka ditetapkan batasan penelitian sebagai berikut.

1. Penelitian menggunakan data historis penjualan ekspor perusahaan yang berasal dari sistem ERP SAP selama tiga tahun, dengan data tahun 2025 sebagai salah satu bagian dari dataset penelitian. Dataset mencakup atribut seperti Order Quantity, Net Price, Net Value, Country, Brand, Season, Material, Currency, dan atribut lain yang tersedia pada sistem SAP.
2. Variabel target penelitian ditentukan berdasarkan hasil eksplorasi data (EDA) terhadap data historis SAP dengan mempertimbangkan karakteristik distribusi data, tingkat kelengkapan data, serta relevansi terhadap kebutuhan perusahaan
3. Model yang dibandingkan dalam penelitian ini dibatasi pada tiga arsitektur Transformer, yaitu:
    1. MoEBS-Transformer
    2. N-Space Transformer
    3. Temporal Fusion Transformer (TFT).

4. Penelitian tidak membahas pengembangan arsitektur baru maupun modifikasi algoritma Transformer, tetapi berfokus pada implementasi, evaluasi, dan analisis komparatif terhadap ketiga model menggunakan dataset yang sama.
5. Evaluasi performa model dilakukan menggunakan metrik:
    1. MAE (Mean Absolute Error)
    2. RMSE (Root Mean Square Error)
    3. MAPE (Mean Absolute Percentage Error)
    4. SMAPE (Symmetric Mean Absolute Percentage Error)
    5. R^2 (Coefficient of Determination).
6. Penelitian tidak membahas integrasi model ke dalam sistem ERP SAP maupun implementasi aplikasi produksi (deployment). Fokus penelitian terbatas pada pengembangan model, evaluasi performa, dan analisis hasil eksperimen.

BAB II TINJAUAN PUSTAKA

2.1 Teori Utama

Pada penelitian ini, teori utama yang digunakan meliputi konsep Forecasting, Time Series Forecasting, Multivariate Time Series, Transformer, Self-Attention, Temporal Fusion Transformer (TFT), N-Space Transformer, dan MoEBS-Transformer. Teori-teori tersebut dipilih karena memiliki hubungan langsung dengan tujuan penelitian, yaitu membandingkan performa tiga model Transformer dalam melakukan peramalan penjualan ekspor berbasis data historis SAP.

2.1.1 Forecasting

Dalam data SAP multivariat, peramalan tidak hanya mengandalkan satu variabel (univariat), tetapi juga mempertimbangkan faktor eksternal (eksogen) seperti biaya produksi dan nilai tukar (Sohrabpour 2021)

Metode	Prinsip Kerja	Kelebihan	Kekurangan	Kesesuaian dengan dataset SAP
Moving Average	Menggunakan rata-rata sebelumnya	Sederhana	Tidak mampu menangkap pola kompleks	Rendah
Exponential Smoothing	Memberikan bobot lebih besar pada data terbaru	Baik untuk data sederhana	Kurang efektif pada multivariat	Rendah
ARIMA	Memodelkan hubungan statistik data time series	Baik untuk data linier	Sulit menangani banyak variabel	Sedang
Random Forest	Ensemble decision tree	Mampu menangani hubungan nonlinier	Kurang optimal pada data sekuensial	Sedang
LSTM	Jaringan saraf	Mampu	Training lebih	Baik

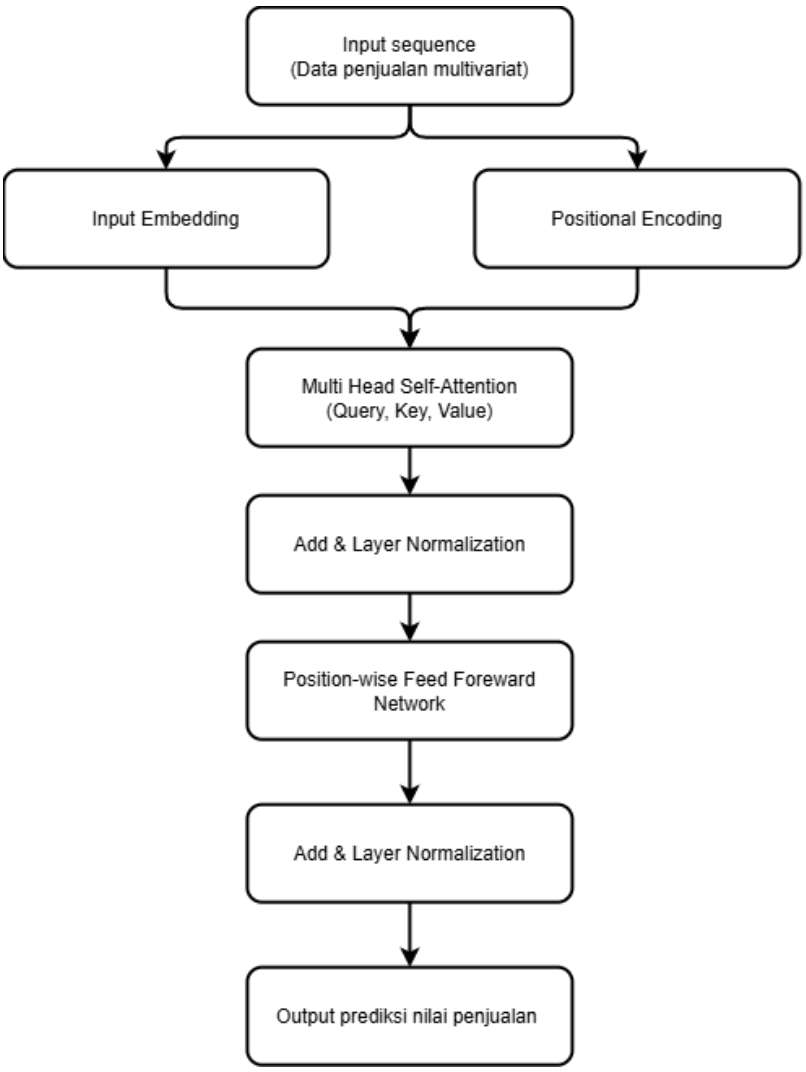
	rekuren	menangkap pola temporal	lambat dan sulit diparalelkan	
Transformer Metode yang diusulkan	**Self-Attention dan Parallel Processing**	**Menangkap dependensi jangka panjang, mendukung data multivariat pelatihan paralel**	**Membutuhkan data yang lebih besar untuk komputasi yang lebih tinggi**	**Sangat Baik**

Tabel 2.1 Perbandingan Algoritma Deep Learning

Berdasarkan klasifikasi metode forecasting pada perbandingan metode pada Tabel 2.1, dapat diketahui bahwa pendekatan berbasis Deep Learning, khususnya Transformer, memiliki kemampuan yang lebih baik dalam menangani data multivariat yang kompleks dibandingkan metode statistik konvensional. Hal ini disebabkan Transformer mampu memanfaatkan mekanisme self-attention untuk mempelajari hubungan jangka panjang antar variabel serta melakukan proses komputasi secara paralel. Karakteristik tersebut sesuai dengan data historis penjualan berbasis SAP yang digunakan pada penelitian ini, sehingga pendekatan Transformer dipilih sebagai metode utama untuk melakukan forecasting.

2.1.2 Arsitektur Transformer dan Mekanisme Self-Attention

Transformer adalah arsitektur *deep learning* yang pertama kali diperkenalkan untuk mengatasi keterbatasan model rekuren dalam memproses data sekuensial. Berbeda dengan RNN yang memproses data secara berurutan, Transformer memanfaatkan mekanisme *self-attention* untuk mempelajari hubungan antar seluruh elemen dalam suatu urutan data secara paralel, sehingga lebih efisien pada data berskala besar dan mampu menangkap ketergantungan jangka panjang tanpa mengalami *vanishing gradient* (Zuo 2020). Mekanisme ini bekerja dengan menghitung bobot relevansi antar posisi data melalui representasi *Queri, Key* dan *Value,* yang kemudian dikombinasikan melalui beberapa *head* secara paralel (*multi-head attention)* untuk menangkap pola relasi sekaligus



Gambar 2.1.2 Alur Pemrosesan Data pada Mekanisme Self-Attention Transformer Diadaptasi dari (Zuo 2020)

1. Input Sequence

   Data penjualan multivariat dengan variabel kuantitas, harga, negara tujuan, musim dan lain-lain yang masuk sebagai satu urutan data ke dalam system

2. Percabangan menjadi dua jalur paralel

   Data di proses secara bersamaan melalui dua jalur yaitu :

   - Input Embedding – mengubah setiap nilai data mentah menjadi representasi vector numerik berdimensi tetap, supaya dapat diproses secara matematis oleh model
   - Positional Encoding – menambahkan informasi urutan waktu ke dalam data, karena Transformer memproses semua data sekaligus

(pararel), tidak seperti RNN yang satu per satu, sehingga model perlu “diberi tahu” secara eksplisit urutan waktunya.

3. Multi Head Self-Attention

   Hasil input Embedding dan Positional Encoding digabungkan dan masuk ke lapisan ini, dimana proses inti terjadi. Model menghitung representasi *Query, Key,* dan *Value* untuk setiap titik data, dan mengukur seberapa relevan setiap titik waktu terhadap titik waktu lainnya (seberapa besar pengaruh pola penjualan bulan lalu terhadap prediksi bulan ini). "multi-head" proses ini dilakukan beberapa kali secara paralel dengan "sudut pandang" berbeda, agar model dapat menangkap beberapa jenis pola relasi sekaligus.

4. Add & Layer Normalization

   Hasil *self-attention* dijumlahkan dengan sinyal input awal atau *residual connection* lalu dinormalisasi. Tujuannya menjaga stabilitas nilai numerik selama pelatihan model, mencegah nilai meledak atau menghilang saat model semakin dalam.

5. Position wise Feed Forward Network

   Data yang sudah di normalisasi diproses lebih lanjut melalui jaringan syaraf sederhana yang bekerja secara independen di setiap titik waktu, untuk memperkaya representasi fitur sebelum ke tahap akhir.

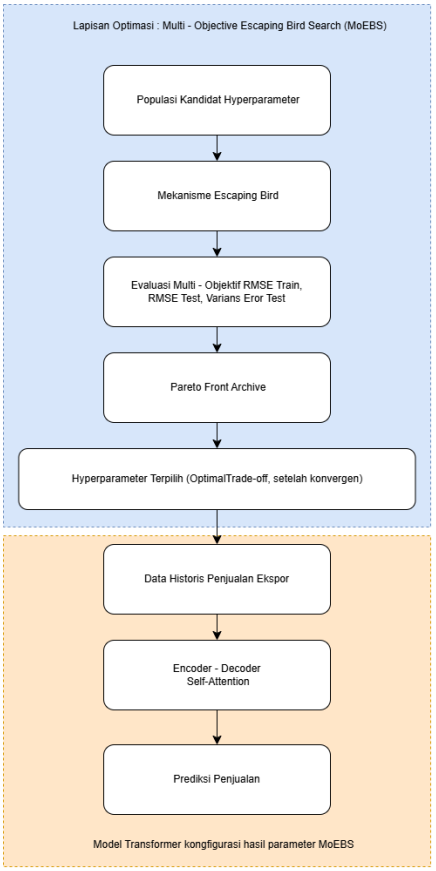
6. Output prediksi penjualan

   Setelah melewati seluruh lapisan model menghasilkan nilai prediksi penjualan ekspor pada periode berikutnya.

Beberapa studi menunjukkan bahwa arsitektur Transformer secara konsisten unggul dibandingkan model rekuren pada berbagai domain deret waktu, seperti peramalan beban listrik jangka pendek (Zhao n.d.), indeks pasar saham (Wang 2022), dan pasar keuangan multi-model (Kehinde 2023). Meskipun demikian, (Zeng 2017) menegaskan bahwa keunggulan tersebut tidak bersifat mutlak dan sangat bergantung pada karakteristik data serta strategi peramalan yang digunakan, sehingga model sederhana seperti Linear tetap perlu disertakan sebagai pembanding untuk menghindari kesimpulan yang bias terhadap satu arsitektur.

2.1.3 MoEBS Transformer

MoEBS-Transformer merupakan arsitektur Transformer yang diperkuat dengan algoritma optimasi *Multi-Objective Escaping Bird Search* (MOEBS) untuk mengatasi permasalahan optimasi hyperparameter yang mudah terjebak pada *local optima* ketika hanya menggunakan pendekatan optimasi tunggal-tujuan. MOEBS mengadaptasi perilaku kawanan burung yang menghindari predator (*escaping bird behavior*) untuk melakukan pencarian solusi secara adaptif dalam ruang multi-objektif (Wei 2025). Algoritma ini menghasilkan populasi kandidat hyperparameter mencakup *learning rate*, jumlah *attention head*, dan koefisien regularisasi yang kemudian dievaluasi secara simultan berdasarkan tiga fungsi objektif: RMSE data latih, RMSE data uji, dan varians error data uji. Solusi-solusi yang tidak terdominasi (*non-dominated solutions*) disimpan dalam *Pareto front archive* dan diperbarui secara iteratif hingga diperoleh kombinasi hyperparameter dengan *trade-off* optimal, yang selanjutnya digunakan untuk mengkonfigurasi model Transformer inti.



Gambar 2.1.3 Arsitektur MoEBS-Transformer: Lapisan Optimasi MOEBS dan Model Transformer Inti diadaptasi dari (Wei 2025)

Lapisan 1 – Optimasi MoEBS

Lapisan ini bekerja sebelum model dilatih, dengan menggunakan pencarian kombinasi *hyperparameter* terbaik, yang berjalan secara interatif dengan mengikuti 4 langkah berikut

1. Populasi Kandidat Hyperparameter
   Dengan membuat kombinasi kandidat algoritma *hyperparameter* secara acak mencangkup *learning rate,* jumlah *attention head,* dan koefisien regularisasi.
2. Mekanisme Escaping Bird / Evasion Behavior Search
   Setiap kandidat bergerak mengikuti perilaku kawanan burung yang menghindari predator, dimana strategi ini sebagai pencarian algoritma MoEBS untuk eksplorasi solusi baru, dan menghindari terjebak solusi yang sama (*local optima*).
3. Evaluasi Multi Objektf
   Setiap kombinasi hyperparameter hasil langkah 2 diuji dengan melatih model transformer, lalu dinilai berdasarkan tiga tujuan, RMSE data latih,RMSE ata uji, dan varians error data uji. Algoritma multi objektif tidak hanya mengejar satu angka terbaik, tapi mencari keseimbangan diantara ketiganya.
4. Pareto Front Archive
   Kombinasi yang lain dari tiga jenis tujuan RMSE data latih,RMSE ata uji, dan varians error data uji, disimpan disini.

Setelah tidak ada perubahan lagi panah menuju Hyperparameter terpilih dengan satu kombinasi terbaik dan paling optimal *trade-off*nya diantara ke tiga tujuan.

Lapisan 2 – Model Transformer Inti

1. Data Historis Penjualan Ekspor

Data yang sudah melalui *preprocessing, encoding* variabel kategorikal, disusun dalam deret waktu multivariat dan siap di input model.

2. Encoder – Decoder Self Attention

   Inti dalam Transformer ini mewakili seluruh alur mulai dari embedding positional encoding, multi head self attention, add & norm, feed forward, yang ditentukan berdasar dari hasil lapisan optimasi proses MoEBS

3. Hasil Prediksi Penjualan

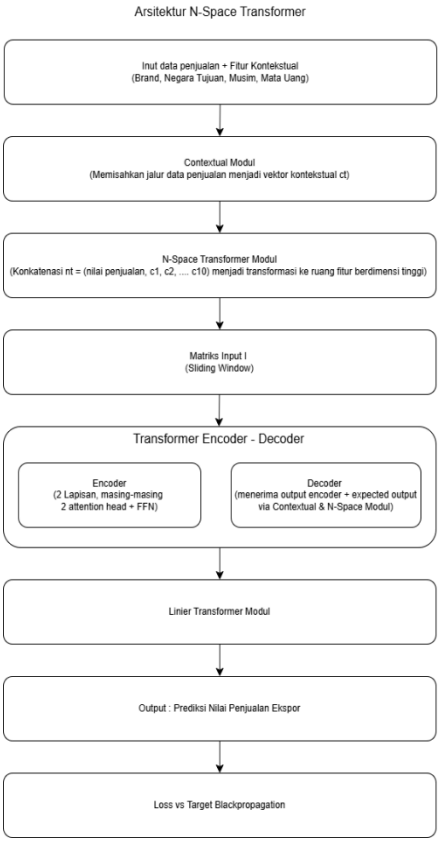
   Setelah data diproses melalui mekanisme *encoder-decoder*, model menghasilkan output berupa angka perkiraan nilai/kuantitas penjualan ekspor untuk periode berikutnya.

Seperti diilustrasikan pada Gambar 2.3, arsitektur ini terdiri atas dua lapisan: lapisan optimasi MOEBS yang bekerja di luar model, dan model Transformer standar (encoder-decoder dengan self-attention) yang parameternya dikonfigurasi oleh hasil optimasi tersebut. Hasil pengujian pada data penutupan harga saham Amazon, Google, dan Uniqlo menunjukkan bahwa MOEBS-Transformer menghasilkan nilai R^2, RMSE, dan RPD yang lebih baik dibandingkan Transformer yang dioptimasi dengan Random Search, Grid Search, Bayesian Optimization, maupun algoritma multi-objektif lain seperti MOMVO dan MSSA (Wei 2025)

2.1.4 N-Space Transformer

N-Space Transformer dikembangkan oleh (Heureux n.d.) dengan memodifikasi alur kerja Transformer NLP standar melalui penambahan dua komponen utama, yaitu *contextual module* dan *N-space transformation module*, serta sebuah *linear transformation module* pada bagian akhir arsitektur. *Contextual module* bertugas memisahkan jalur pemrosesan antara data numerik (nilai penjualan) dan fitur kontekstual (misalnya negara tujuan, musim, merek), menghasilkan vektor kontekstual c□. Selanjutnya, *N-space transformation module* menggabungkan vektor kontekstual dengan nilai penjualan menjadi satu vektor n□, kemudian mentransformasikannya ke ruang fitur berdimensi lebih tinggi untuk memperkaya representasi yang diproses oleh *multi-head attention*. Vektor hasil transformasi ini membentuk matriks input yang diproses melalui *encoder* (dua lapisan,

masing-masing dengan dua *attention head*) dan *decoder*, sebelum akhirnya melalui *linear transformation module* untuk menghasilkan prediksi akhir,



Gambar 2.1.4 Arsitektur N-Space Transformer: Contextual Module, N-Space Transformation, dan Encoder-Decoder diadaptasi dari (Heureux n.d.)

1. **Input: Data Penjualan + Fitur Kontekstual**

   Data mentah masuk ke sistem, terdiri dari dua jenis: nilai penjualan (angka) dan fitur kontekstual seperti *brand*, negara tujuan, musim, dan mata uang.

2. **Contextual Module**

   Di sinilah letak keunikan pertama N-Space Transformer dibanding Transformer biasa. Modul ini **memisahkan jalur pemrosesan** antara data numerik (nilai penjualan) dan fitur kontekstual, lalu mengubah fitur-fitur kontekstual tersebut (yang sifatnya kategorikal, seperti nama negara atau musim) menjadi vektor numerik yang disebut **vektor kontekstual (c□)**. Tujuannya supaya informasi "konteks bisnis" ini bisa diproses secara matematis bersama data penjualan.

3. **N-Space Transformation Module**

   Vektor kontekstual (c□) dari langkah sebelumnya digabungkan (dikonkatenasi) dengan nilai penjualan menjadi satu vektor gabungan yang disebut **n□**. Vektor gabungan ini kemudian ditransformasikan ke **ruang fitur berdimensi lebih tinggi** istilahnya "N-space transformation", karena mengubah representasi data ke ruang matematis dengan lebih banyak dimensi. Tujuannya supaya mekanisme *attention* di tahap berikutnya bisa menangkap hubungan antar variabel (misalnya "penjualan naik di negara tertentu saat musim tertentu") secara lebih kaya, bukan hanya melihat angka penjualan saja seperti Transformer standar.

4. **Matriks Input I / Sliding Window**

   Hasil transformasi disusun menjadi matriks input menggunakan teknik *sliding window* data dipecah menjadi potongan-potongan urutan waktu (misalnya data 12 minggu terakhir) yang menjadi satu unit masukan untuk model.

5. **Transformer Encoder–Decoder**

   Di dalam kotak ini ada dua bagian:

   - **Encoder** terdiri dari 2 lapisan, masing-masing berisi 2 *attention head* dan *feed-forward network*, bertugas mempelajari pola dari data historis yang masuk.

   - **Decoder** selain menerima output dari Encoder, decoder juga menerima *"expected output"* / nilai target periode berikutnya, saat pelatihan yang juga sudah diproses lebih dulu melalui Contextual Module dan N-Space Transformation Module yang sama inilah kenapa kedua modul tadi digambar sebagai satu alur yang dipakai berulang, bukan cuma sekali di awal.

6. **Linear Transformation Module**

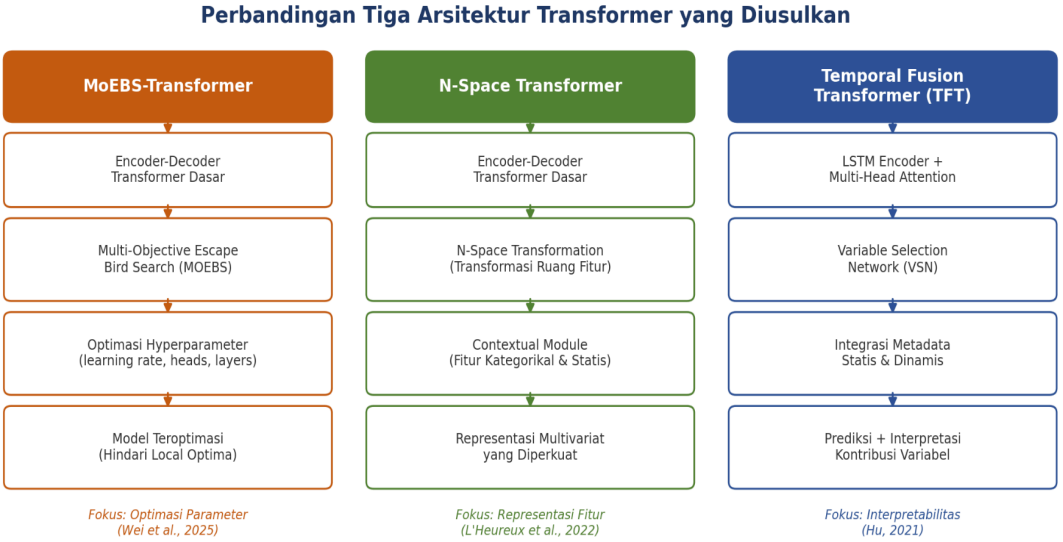
   Setelah keluar dari decoder, hasilnya melewati satu lapisan transformasi linear untuk mengubah representasi internal model menjadi format angka prediksi akhir yang bisa dibaca.

7. **Output: Prediksi Nilai Penjualan Ekspor**
   Inilah hasil akhir perkiraan nilai penjualan ekspor untuk periode berikutnya.
8. **Loss vs Target : Backpropagation**
   Selama proses pelatihan, hasil prediksi dibandingkan dengan nilai sebenarnya untuk menghitung *loss* (selisih kesalahan). Nilai ini kemudian dipakai untuk memperbarui bobot di tiga bagian sekaligus: Encoder, Decoder, dan N-Space Transformation Module artinya modul transformasi fitur ini bukan cuma langkah preprocessing statis, tapi ikut "belajar" dan disesuaikan selama pelatihan model

Model ini terbukti unggul dibandingkan pendekatan *Sequence-to-Sequence* (Seq2Seq) berbasis RNN pada peramalan beban listrik di 20 aliran data yang berbeda (Heureux n.d.), khususnya pada data dengan banyak variabel kontekstual yang saling berkaitan karakteristik yang serupa dengan data penjualan ekspor multivariat pada penelitian ini.

2.1.5 Temporal Fusion Transformer (TFT)

Temporal Fusion Transformer (TFT) dirancang untuk menggabungkan kemampuan pemrosesan sekuensial LSTM dengan mekanisme *multi-head attention* yang dapat diinterpretasikan. Komponen utama TFT adalah *Variable Selection Network* (VSN), yang secara otomatis memilih dan memberikan bobot relevansi terhadap variabel statis maupun dinamis yang paling berkontribusi terhadap hasil prediksi (Hu 2021). Karakteristik ini menjadikan TFT tidak hanya menghasilkan prediksi yang akurat, tetapi juga memberikan interpretasi mengenai variabel apa saja (misalnya negara tujuan, musim, atau merek) yang paling memengaruhi pola penjualan sebuah keunggulan yang tidak dimiliki model Transformer standar.



Gambar 2.1.5 Perbandingan Komponen Utama MoEBS-Transformer, N-Space Transformer, dan TFT diolah dari (Heureux n.d.; Hu 2021; Wei 2025)

2.2 Teori Pendukung

2.2.1 Multivariate Time Series Forecasting

Data deret waktu multivariat merupakan data yang terdiri atas beberapa variabel yang saling berkaitan dan diamati secara berurutan dalam periode waktu tertentu. Berbeda dengan peramalan univariat yang hanya mempertimbangkan satu variabel target, peramalan multivariat perlu mempertimbangkan interaksi antar variabel input dan target secara simultan, sehingga membutuhkan model yang mampu menangkap relasi kompleks antar dimensi data (Salehi 2024). Pada konteks penelitian ini, data penjualan ekspor bersifat multivariat karena melibatkan variabel kuantitas penjualan, harga, negara tujuan, musim, mata uang, merek, dan kode produk yang saling mempengaruhi pola penjualan.

2.2.2 Recurrent Neural Network, LSTM, dan GRU sebagai Baseline

Recurrent Neural Network (RNN) beserta variannya, *Long Short-Term Memory* (LSTM) dan *Gated Recurrent Unit* (GRU), merupakan arsitektur yang secara historis banyak digunakan untuk peramalan deret waktu karena kemampuannya memproses data secara sekuensial (Hewamalage, Bergmeir, and Bandara 2020). Namun, arsitektur ini memiliki keterbatasan berupa proses

pelatihan yang tidak dapat diparalelkan serta kerentanan terhadap *vanishing gradient* pada urutan data yang panjang. Beberapa studi komparatif menunjukkan bahwa Transformer secara konsisten menghasilkan performa yang lebih baik dibandingkan RNN/LSTM/GRU pada berbagai domain (Giap 2025; Kehinde 2023; Prediction and Xiao n.d.), sehingga ketiga model rekuren ini digunakan sebagai baseline pembanding dalam penelitian ini.

2.2.3 Metrik Evaluasi Model Peramalan

Evaluasi performa model peramalan pada penelitian ini menggunakan lima metrik utama: *Mean Absolute Error* (MAE), *Root Mean Square Error* (RMSE), *Mean Absolute Percentage Error* (MAPE), *Symmetric Mean Absolute Percentage Error* (SMAPE), dan *Coefficient of Determination* (R^2), yang secara umum digunakan pada studi-studi peramalan penjualan dan deret waktu sebelumnya (Kehinde 2023; Wang and Zhao 2023). Selain metrik akurasi, penelitian ini juga mempertimbangkan efisiensi komputasi berupa waktu pelatihan dan waktu inferensi sebagai bahan pertimbangan praktis dalam merekomendasikan model.

2.2.4 Pengambilan Keputusan Berbasis Data (Data-Driven Decision Making)

Konsep *data-driven decision making* menekankan bahwa keputusan organisasi seharusnya didasarkan pada bukti dan hasil analisis data historis, bukan semata-mata pada intuisi atau pengalaman (Elgendy 2022). Dalam konteks ini, hasil peramalan penjualan yang akurat menjadi input penting bagi keputusan operasional seperti perencanaan produksi dan pengendalian persediaan (Tadayonrad and Ndiaye 2023), sehingga pemilihan model peramalan yang tepat memiliki implikasi langsung terhadap kualitas pengambilan keputusan perusahaan.

2.3 Penelitian Terdahulu

Beberapa penelitian terdahulu yang relevan dengan topik penelitian ini dirangkum pada Tabel 2.1 berikut. Baris yang ditandai warna oranye merupakan jurnal acuan utama yang menjadi dasar teori tiga model yang dibandingkan dalam penelitian ini.

Tabel 2.2 Penelitian Terkait

No	Topik	Metode	Hasil	Ref
1.	**L'Heureux, Grolinger, dan Capretz (2022)** *Transformer-Based Model for Electrical Load Forecasting*	N-Space Transformer	Transformer mampu menangani data time series dengan contextual features dan sliding window. Sangat relevan dengan data SAP multivariat.	[1]
2.	**Hu (2021)** *Stock Price Prediction Based on Temporal Fusion Transformer*	Temporal Fusion Transformer, LSTM, SVR	TFT menghasilkan akurasi terbaik melalui pemanfaatan variabel statis dan temporal serta memiliki interpretabilitas yang tinggi.	[2]
3.	**Wei (2023)** *MOEBS-Transformer: A Transformer-Based Forecasting Model with Metaheuristic Optimization*	MOEBS-Transformer	Optimasi metaheuristik meningkatkan stabilitas model dan menghasilkan nilai RMSE serta R^2 yang lebih baik dibanding Transformer standar.	[3]
4.	**Kehinde (2024)** *Financial Market Forecasting using RNN, LSTM, BiLSTM, GRU and Transformer Models*	RNN, LSTM, BiLSTM, GRU, Transformer	Transformer menunjukkan performa prediksi yang lebih baik dibandingkan model rekuren pada data pasar finansial.	[4]
5.	**Wang, Chen, Zhang, dan**	Deep Transformer, CNN, RNN, LSTM	Deep Transformer menghasilkan MAE dan	[5]

	Zhang (2022) *Stock Market Index Prediction Using Deep Transformer Model*		RMSE yang lebih rendah dibanding CNN, RNN, dan LSTM.	
6.	**Xiao (2024)** *Comparative Analysis of LSTM, GRU and Transformer Models for Stock Price Prediction*	LSTM, GRU, Transformer	LSTM memberikan performa tinggi, sedangkan Transformer menunjukkan potensi yang baik pada data sekuensial dengan kompleksitas tinggi.	[6]
7.	**Zhao (2021)** *Short-Term Load Forecasting Based on the Transformer Model*	Transformer, LightGBM, K-Means	Transformer menghasilkan nilai MAPE yang lebih baik dibandingkan RNN dan LSTM dalam prediksi beban listrik jangka pendek.	[7]
8.	**L'Heureux, Grolinger, dan Capretz (2022)** *Transformer-Based Model for Electrical Load Forecasting*	Transformer	Transformer mampu melakukan parallel processing sehingga meningkatkan efisiensi komputasi dan akurasi forecasting.	[8]
9.	**Azad, Sabrina, dan Wasimi (2020)** *Transformation of Smart Grid Using Machine Learning*	ANN, SVM, KNN, Reinforcement Learning	Machine Learning berpotensi meningkatkan prediksi konsumsi energi dan mendukung pengambilan keputusan pada Smart Grid.	[9]

10.	**Zeng (2023)** *Are Transformers Effective for Time Series Forecasting?*	LTSF-Linear, Transformer	Menunjukkan bahwa Transformer tidak selalu lebih unggul pada seluruh kasus time series sehingga diperlukan evaluasi komprehensif terhadap berbagai model.	[10]
11.	**Zuo, Jiang, Li, Zhao, dan Zha (2020)** *Transformer Hawkes Process*	Transformer Hawkes Process	Self-attention terbukti mampu menangkap dependensi jangka panjang secara lebih efektif dibandingkan pendekatan rekuren.	[11]

Berdasarkan dari sisi perbandingan Transformer pada model rekuren, semua metode melakukan perbandingan langsung (Kehinde 2024; Wang 2022; Xiao 2024; Zhao 2021; Zuo 2020) secara konsisten menunjukan Transformer unggul dalam menangkap ketergantungan jangka panjang dibandingkan RNN, LSTM. BiLSTM, maupun GRU, dengan tabel 2.1. Zeng (2023) justru menunjukkan bahwa model linier sederhana (LTSF-Linear) dapat menyamai atau melampaui Transformer pada beberapa kasus time series, sementara Xiao (2024) mencatat LSTM tetap memberikan performa yang kompetitif pada data sekuensial tertentu. Hal ini menegaskan bahwa keunggulan Transformer bersifat kondisional terhadap karakteristik data, sehingga perbandingan langsung antar-arsitektur Transformer sendiri bukan hanya terhadap baseline rekuren menjadi penting untuk dilakukan. Dari Tiga jurnal utama membandingkan satu sama lain dari sisi pendekatan MoEBS-Transformer (Wei 2025) berfokus pada optimasi hyperparameter melalui algoritma metaheuristik multi-objektif di luar arsitektur inti, sehingga keunggulannya terletak pada stabilitas dan menghindari local optima, bukan pada mekanisme internal Transformer itu sendiri. N-Space Transformer (L'Heureux, Grolinger, dan Capretz 2022) sebaliknya memodifikasi arsitektur internal melalui Contextual Module dan N-Space Transformation sebelum data masuk ke

encoder-decoder, sehingga unggul dalam mengintegrasikan fitur kontekstual eksternal. Sementara TFT (Hu 2021) menambahkan Variable Selection Network yang memberi bobot relevansi antar variabel, sehingga unggul dari sisi interpretabilitas, bukan semata akurasi. Ketiga pendekatan ini pada dasarnya menyelesaikan masalah yang berbeda. optimasi hyperparameter vs. integrasi fitur kontekstual vs. interpretabilitas variabel, sehingga belum dapat disimpulkan mana yang paling unggul tanpa diuji pada dataset dan kondisi komputasi yang sama inilah yang menjadi dasar metode eksperimen komparatif pada penelitian ini **Peneliti akan membandingkan performa dari tiga model berdasarkan penelitian terdahulu.** Akan tetapi, sebagian besar penelitian masih dilakukan pada bidang energi, kelistrikan, maupun pasar saham. Selain itu, penelitian terdahulu umumnya hanya mengevaluasi akurasi prediksi tanpa membandingkan beberapa arsitektur Transformer dalam satu kerangka eksperimen yang sama. Kondisi tersebut menunjukkan masih adanya peluang penelitian pada domain penjualan ekspor berbasis ERP SAP yang memiliki karakteristik multivariate time series serta fitur kontekstual yang lebih kompleks.

2.4 Gap Penelitian

Meskipun ketiga jurnal (Heureux 2022.; Hu 2021; Wei 2025) memberikan landasan teori dan bukti empiris yang kuat mengenai keunggulan masing-masing arsitektur, terdapat beberapa kesenjangan yang menjadi dasar penelitian ini:

1. **Domain data.** Ketiga model sebelumnya diuji pada domain yang berbeda dari penjualan ekspor manufaktur: MoEBS-Transformer pada data pasar saham (Wei 2025), N-Space Transformer pada beban listrik (Heureux n.d.), dan TFT pada harga saham (Hu 2021), Belum ada penelitian yang menerapkan ketiganya pada data penjualan ekspor multivariat berbasis ERP SAP.

2. **Perbandingan tunggal, bukan komparatif tiga model.** Setiap studi acuan hanya mengevaluasi satu arsitektur terhadap baseline RNN/LSTM/Transformer standar, belum ada kerangka evaluasi yang membandingkan ketiga arsitektur (MoEBS-Transformer, N-Space Transformer, TFT) secara langsung dalam satu eksperimen yang setara.

3. **Karakteristik fitur kontekstual bisnis.** Fitur kontekstual pada studi acuan bersifat teknis-fisik (kondisi pasar saham, beban listrik), berbeda dengan fitur kontekstual bisnis pada penelitian ini (negara tujuan, musim, merek, mata uang) yang memiliki karakteristik kategorikal dan pola musiman yang berbeda.

4. **Evaluasi efisiensi komputasi belum komprehensif.** Studi acuan lebih berfokus pada akurasi prediksi, sementara aspek efisiensi komputasi (waktu pelatihan dan inferensi) yang relevan untuk implementasi praktis di lingkungan bisnis belum dievaluasi secara mendalam pada ketiga model tersebut.

Berdasarkan kesenjangan tersebut, penelitian ini memposisikan diri sebagai perluasan dan pengujian silang (cross-domain validation) terhadap tiga arsitektur Transformer yang sebelumnya terbukti unggul pada domainnya masing-masing, dengan menerapkannya secara komparatif pada konteks baru yaitu peramalan penjualan ekspor multivariat berbasis data historis SAP.

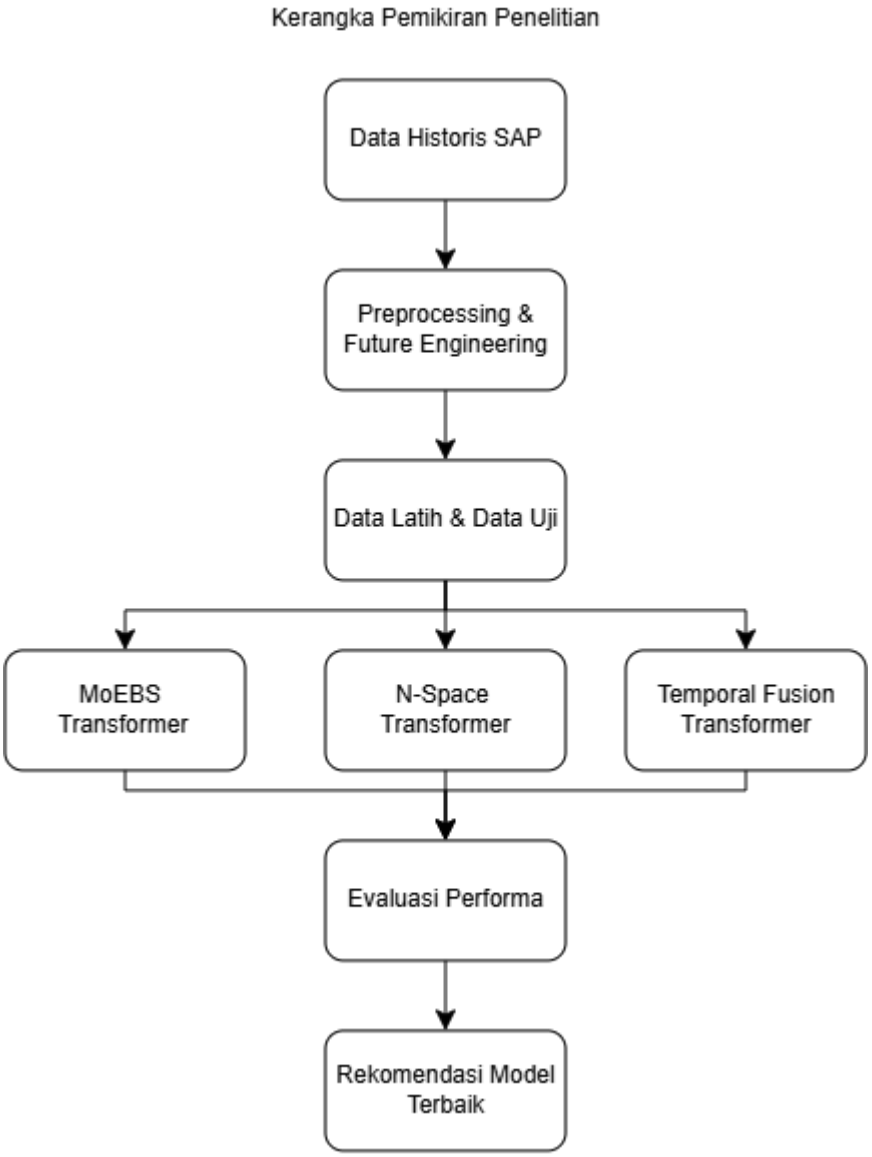
BAB III METODE PENELITIAN

3.1 Pendekatan Penelitian

Penelitian ini menggunakan pendekatan *kuantitatif* dengan metode *eksperimen komparatif* (comparative experimental research). Pendekatan kuantitatif dipilih karena penelitian ini bertujuan mengukur dan membandingkan performa model secara numerik melalui metrik evaluasi yang terukur (MAE, RMSE, MAPE, SMAPE, dan R^2), bukan menginterpretasikan makna atau persepsi secara kualitatif (Kehinde , 2023; Xiao , 2024). Metode eksperimen komparatif diterapkan dengan melatih dan menguji tiga arsitektur Transformer MoEBS-Transformer, N-Space Transformer, dan Temporal Fusion Transformer (TFT) pada dataset yang sama, dalam kondisi pembagian data dan lingkungan komputasi yang identik, sehingga perbedaan hasil yang diperoleh dapat diatribusikan secara valid pada perbedaan arsitektur model, bukan pada faktor eksternal lain.

3.2 Desain Penelitian

Penelitian ini dirancang mengikuti kerangka pemikiran pada Gambar 3.1, yang menggambarkan alur mulai dari pengumpulan data historis penjualan ekspor dari sistem ERP SAP, tahap *preprocessing* dan *feature engineering*, pembagian data latih dan data uji, implementasi serta pelatihan ketiga model Transformer secara paralel dan setara, evaluasi performa berdasarkan metrik yang telah ditentukan, hingga penarikan rekomendasi model yang paling sesuai untuk mendukung pengambilan Keputusan



Gambar 3.1 Desain dan Kerangka Pemikiran Penelitian

Desain ini bersifat *within-subject comparison*, yaitu ketiga model diuji pada dataset, skema pembagian data, dan environment komputasi yang sama persis, sehingga variabel pembanding hanya terletak pada arsitektur model itu sendiri. Desain semacam ini mengikuti praktik umum pada studi-studi komparatif sejenis (Hu, 2021; Wei , 2025; L'Heureux , 2022) untuk menjamin validitas internal perbandingan

3.3 Subjek Penelitian

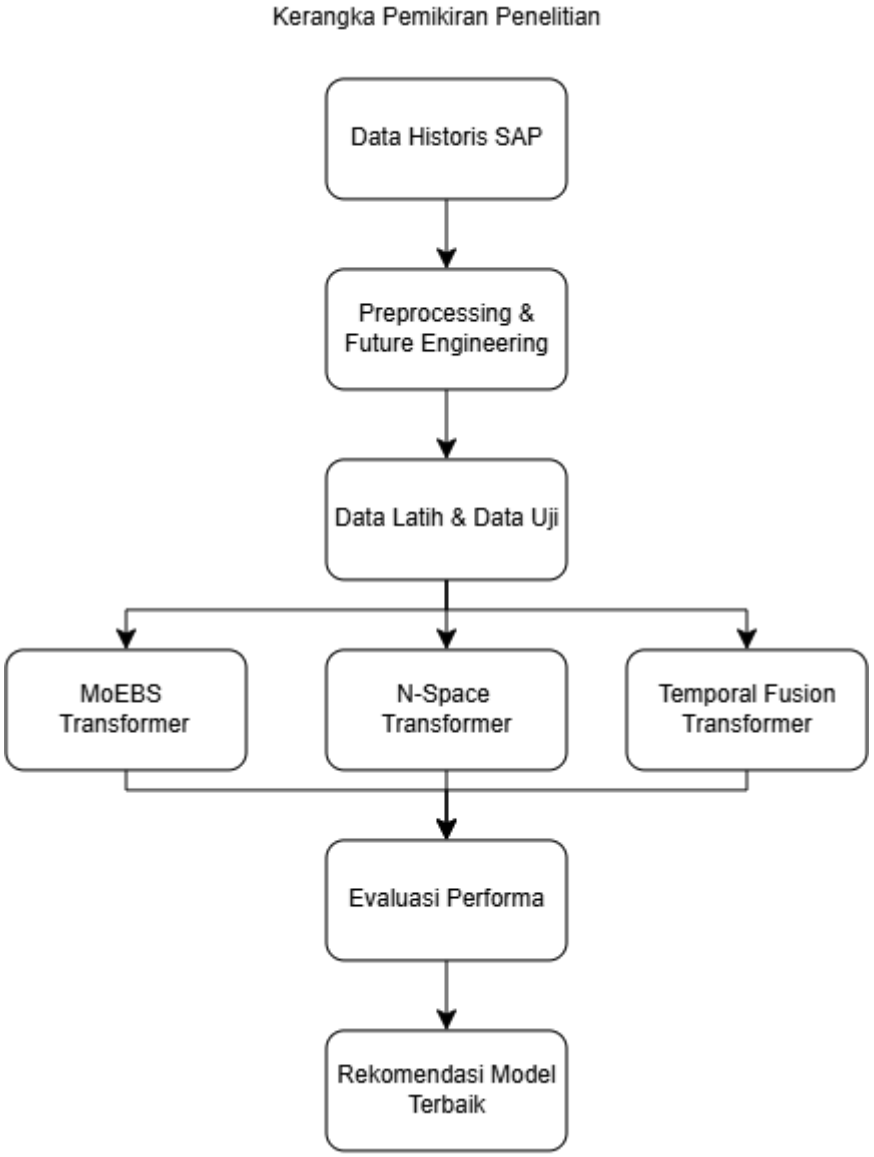
Perlu digarisbawahi bahwa istilah *subjek penelitian* pada konteks penelitian kuantitatif-eksperimental seperti ini berbeda maknanya dari penelitian sosial/kualitatif. Yang menjadi *objek penelitian* adalah data historis transaksi penjualan ekspor pada modul *Sales & Distribution* (SD) sistem ERP SAP milik perusahaan manufaktur berorientasi ekspor, sedangkan yang menjadi *subjek eksperimen* adalah ketiga model Transformer yang diuji: MoEBS-Transformer, N-Space Transformer, dan Temporal Fusion Transformer (TFT).

Data yang digunakan terdiri atas tiga berkas ekstraksi tahunan sebagaimana dirangkum pada Tabel 3.1:

Berkas	Jumlah Baris	Keterangan
VAL_2023.XLSX	22.459	Data mulai 15 Jul 2023, namun volume signifikan baru sejak Des 2023
VAL_2024.XLSX	60.052	Data penuh 1 tahun (Jan–Des 2024)
VAL_2025.XLSX	35.655	Data s.d. 31 Des 2025
Total	**118.166 (117.863 bertanggal valid)**	Rentang efektif: Des 2023 – Des 2025 (±25 bulan)

Setiap baris data merepresentasikan satu item transaksi penjualan ekspor, dengan atribut meliputi tanggal transaksi (*KP Date*), kuantitas penjualan (*Order Quantity (Item)*), harga (*Net Price*), nilai penjualan (*Net Value (Item)*), negara tujuan (*Country Key*), musim (*Season*), mata uang (*Document Currency*), merek, serta kode produk (*Material*). Identitas perusahaan tidak disebutkan secara eksplisit dalam laporan penelitian ini untuk menjaga kerahasiaan data bisnis, sesuai kesepakatan dengan pihak perusahaan.

3.4 Instrumen Penelitian



Instrumen yang digunakan dalam penelitian ini terbagi menjadi perangkat keras, perangkat lunak, dan pustaka (library) pemrograman sebagai berikut:

Kategori	Instrumen
Bahasa Pemrograman	Python 3.x
Framework Deep Learning	PyTorch / TensorFlow-Keras (disesuaikan dengan implementasi acuan masing-masing model)
Pustaka Pendukung	Pandas & NumPy (manipulasi data), Scikit-learn (preprocessing & metrik evaluasi), Matplotlib/Seaborn (visualisasi)

Kategori	Instrumen
Lingkungan Komputasi	Google Colab / Jupyter Notebook dengan akselerasi GPU (untuk menjamin konsistensi waktu pelatihan antar model)
Sumber Data	Ekspor data dari modul Sales & Distribution (SD) sistem ERP SAP dalam format .xlsx (VAL_2023, VAL_2024, VAL_2025)

Arsitektur MoEBS-Transformer, N-Space Transformer, dan TFT diimplementasikan dengan mengadaptasi struktur model yang dipaparkan pada jurnal acuan utama (Wei , 2025; L'Heureux , 2022; Hu, 2021), dengan penyesuaian pada dimensi input agar sesuai dengan karakteristik data penjualan ekspor multivariat pada penelitian ini.

3.5 Teknik Pengumpulan Data

Data yang digunakan dalam penelitian ini merupakan data sekunder berupa data historis transaksi penjualan ekspor periode **15 Juli 2023 – 31 Desember 2025**, yang diekstraksi langsung dari sistem ERP SAP perusahaan. Teknik pengumpulan data dilakukan melalui tahapan berikut:

1. Ekstraksi data dari modul Sales & Distribution (SD) SAP untuk periode tahun 2023, 2024, dan 2025 ke dalam tiga berkas terpisah (VAL_2023.XLSX, VAL_2024.XLSX, VAL_2025.XLSX).
2. Data digabungkan (concatenated) menjadi satu dataset terpadu berjumlah 118.166 baris transaksi, diurutkan secara kronologis berdasarkan tanggal transaksi.
3. Data diverifikasi kelengkapannya, termasuk pemeriksaan nilai tanggal yang tidak valid (303 baris tanpa tanggal terisi) dan konsistensi format antar berkas.

3.6 Analisis Data

3.6.1 Data Preprocessing

Tahap preprocessing meliputi pembersihan data (penanganan nilai hilang dan duplikasi), normalisasi/standardisasi variabel numerik, serta *encoding* variabel kategorikal (negara tujuan, musim, merek, mata uang) menggunakan

teknik yang sesuai dengan kebutuhan masing-masing model misalnya *embedding* kategorikal untuk N-Space Transformer mengikuti pendekatan *contextual module* (L'Heureux , 2022), atau enkode variabel statis untuk *Variable Selection Network* pada TFT (Hu, 2021).

Temuan penting selama eksplorasi data awal menunjukkan bahwa kolom *Net Value (Item)* dicatat dalam dua mata uang berbeda: 117.824 baris dalam USD dan 341 baris dalam IDR. Karena skala nilai Rupiah jauh lebih besar secara nominal, penjumlahan langsung tanpa konversi menyebabkan distorsi signifikan pada agregasi bulanan (misalnya lonjakan semu pada Februari 2025). Oleh karena itu, seluruh nilai dalam IDR **wajib dikonversi ke USD** menggunakan kurs historis pada tanggal transaksi terkait sebelum data digunakan sebagai fitur maupun target model, sebagai bagian dari tahap preprocessing.

3.6.2 Feature Engineering & Sliding Window

Data time series disusun menjadi struktur *sliding window* dengan panjang jendela historis tertentu sebagai input dan periode berikutnya sebagai target prediksi, mengikuti pendekatan yang digunakan pada N-Space Transformer (L'Heureux , 2022). Data transaksi harian diagregasikan pada level mingguan per kombinasi negara tujuan dan merek, mengingat volume transaksi harian bersifat jarang (sparse) untuk sebagian kombinasi kategori.

3.6.3 Pembagian Data

Karena data bersifat deret waktu, pembagian data **tidak dilakukan secara acak**, melainkan berdasarkan urutan kronologis untuk mencegah kebocoran data (*data leakage*) dari periode mendatang ke proses pelatihan. Berdasarkan eksplorasi terhadap dataset gabungan (118.166 baris, periode Juli 2023–November 2025), penelitian ini menggunakan skema pembagian 80:10:10 berbasis batas bulan kalender sebagai berikut:

Subset	Periode	Proporsi	Estimasi Baris
Data Latih	Desember 2023 – Juni 2025 (19 bulan)	≈85.9%	≈94.000
Data Validasi	Juli – Agustus 2025 (2 bulan)	≈5.5%	≈12.000
Data Uji	September – November 2025 (3 bulan)	≈8.6%	≈12.000

Skema 80:10:10 dipilih mengingat rentang data historis yang tersedia relatif terbatas (±25 bulan), sehingga porsi data latih yang lebih besar diperlukan agar model khususnya arsitektur Transformer yang umumnya membutuhkan data dalam jumlah memadai dapat mempelajari pola musiman minimal satu siklus tahunan penuh sebelum dievaluasi. Pembagian dilakukan berdasarkan batas bulan kalender (Chronological boundary-based split) bukan berdasarkan jumlah baris, untuk menjaga pola musiman tetap utuh pada masing-masing subset dan mencegah kebocoran data antar periode. Konsekuensi proporsi aktual yang diperoleh 85,9% : 5,5% : 8,6% hal ini disengaja demi menjaga integritas batas waktu, bukan kesalahan dalam perhitungan. Data bulan Desember 2025 dikeluarkan dari data uji karena data belum genap satu bulan. Data bulan Juli 2023 (3 baris) dikeluarkan dari analisis karena tidak representatif. Selain itu, ditemukan lonjakan volume transaksi pada Juni 2025 (14.855 baris, sekitar tiga kali volume bulan normal) yang setelah ditelusuri merupakan peningkatan permintaan ekspor yang wajar (tersebar pada 534 dokumen penjualan berbeda di berbagai negara tujuan, bukan duplikasi data), sehingga tetap dipertahankan dalam data latih.

3.6.4 Implementasi dan Pelatihan Model

Ketiga model dilatih secara terpisah dengan skema pembagian data dan lingkungan komputasi yang identik untuk menjamin keadilan perbandingan (fair comparison):

1. MoEBS-Transformer: hyperparameter (learning rate, jumlah attention head, koefisien regularisasi) dioptimasi melalui algoritma Multi-Objective Escaping Bird Search sebelum pelatihan akhir (Wei , 2025).
2. N-Space Transformer: data melalui Contextual Module dan N-Space Transformation Module sebelum masuk ke Encoder-Decoder (L'Heureux , 2022).
3. Temporal Fusion Transformer (TFT): variabel statis dan dinamis diproses melalui Variable Selection Network sebelum masuk ke LSTM Encoder dan lapisan attention (Hu, 2021).

3.7 Prosedur Penelitian

Prosedur penelitian dilaksanakan melalui tahapan berikut, sesuai kerangka pemikiran pada Gambar 3.1:

1. Studi literatur dan penetapan kerangka teori.
2. Pengumpulan dan ekstraksi data historis penjualan ekspor dari sistem ERP SAP (VAL_2023, VAL_2024, VAL_2025) serta penggabungan menjadi satu dataset terpadu.
3. Data preprocessing (pembersihan data, konversi mata uang IDR ke USD, encoding variabel kategorikal), feature engineering (agregasi mingguan, sliding window), dan pembagian data latih/validasi/uji secara kronologis (80:10:10).
4. Implementasi ketiga arsitektur Transformer (MoEBS-Transformer, N-Space Transformer, TFT) mengikuti spesifikasi pada jurnal acuan utama.
5. Pelatihan (training) masing-masing model pada data latih dengan environment komputasi yang sama.
6. Pengujian (testing) masing-masing model pada data uji yang belum pernah dilihat model sebelumnya.
7. Evaluasi dan perbandingan performa ketiga model berdasarkan metrik MAE, RMSE, MAPE, SMAPE, R^2, serta efisiensi komputasi (waktu pelatihan dan inferensi).
8. Analisis hasil dan penyusunan rekomendasi model yang paling sesuai untuk mendukung pengambilan keputusan penjualan dan persediaan perusahaan.

3.8 Evaluasi Hasil Penelitian

Evaluasi performa model dilakukan menggunakan metrik-metrik berikut, yang secara umum digunakan pada studi peramalan deret waktu sejenis (Kehinde 2023; Zhao 2021; Wei 2025):

Metrik	Kegunaan	Interpretasi
MAE	Mengukur rata-rata besar kesalahan absolut prediksi	Semakin kecil, semakin akurat

Metrik	Kegunaan	Interpretasi
RMSE	Mengukur kesalahan dengan penalti lebih besar pada outlier	Semakin kecil, semakin akurat
MAPE	Mengukur kesalahan dalam bentuk persentase	Memudahkan interpretasi lintas skala data
SMAPE	Versi simetris MAPE, lebih stabil pada nilai mendekati nol	Mengatasi bias MAPE pada data kecil
R^2	Mengukur proporsi variansi target yang dijelaskan model	Mendekati 1 = semakin baik
Waktu Komputasi	Mengukur waktu pelatihan dan waktu inferensi model	Pertimbangan efisiensi praktis implementasi

Model dengan kombinasi nilai metrik akurasi terbaik dan waktu komputasi yang wajar akan direkomendasikan sebagai model yang paling sesuai untuk mendukung pengambilan keputusan penjualan dan persediaan perusahaan, menjawab rumusan masalah dan tujuan penelitian pada Bab I.

DAFTAR PUSTAKA

Dai, Linfabao, Wenming Chen, Mingqing Xiao, Wenhao Sun, and Zhengzheng Wang. 2025. "Prediction of Super-Large Diameter Shield Attitude Based on LSTM- Transformer." 1–23.

Eglite, Linda, and Ilze Birzniece. 2022. "Retail Sales Forecasting Using Deep Learning : Systematic Literature Review." (30):53–62.

Elgendy, Nada, Ahmed Elragal, Tero Päivärinta, Nada Elgendy, and Ahmed Elragal. 2022. "DECAS : A Modern Data-Driven Decision Theory for Big Data and Analytics and Analytics." *Journal of Decision Systems* 31(4):337–73. doi: 10.1080/12460125.2021.1894674.

Giap, Quang Huy, Thi Thanh, Quynh Nguyen, and Trung Hieu Trinh. 2025. "Toward Enhancing Mid-Term Load Forecasting : RNN-Based Models vs Transformer-Based Models." 19:397–404.

Heureux, Alexandra L., Katarina Grolinger, Miriam A. M. Capretz, and Katarina Grolinger. n.d. "Transformer-Based Model for Electrical Load Forecasting Transformer-Based Model for Electrical Load Forecasting."

Hewamalage, Hansika, Christoph Bergmeir, and Kasun Bandara. 2020. "Recurrent Neural Networks for Time Series Forecasting : Current Status and Future Directions." *International Journal of Forecasting* (xxxx). doi: 10.1016/j.ijforecast.2020.06.008.

Hu, Xiaokang. 2021. "Stock Price Prediction Based on Temporal Fusion Transformer." 60–66.

Kehinde, T. O. 2023. "Financial Market Forecasting Using RNN , LSTM , BiLSTM , GRU and Transformer-Based Deep Learning Algorithms." 393–403.

Prediction, Stock Price, and Jue Xiao. n.d. *Comparative Analysis of LSTM GRU and Transformer Models For*. Vol. 1. Association for Computing Machinery.

Rajagopal, Navaneetha Krishnan, Naila Iqbal Qureshi, S. Durga, Edwin Hernan, Ramirez Asis, Rosario Mercedes, Huerta Soto, Shashi Kant Gupta, and S. Deepak. 2022. "Future of Business Culture : An Artificial Intelligence-Driven Digital Framework for Organization Decision-Making Process." 2022. doi: 10.1155/2022/7796507.

Salehi, Sajad, Miroslava Kavgic, Hossein Bonakdari, and Luc Begnoche. 2024. "Energy and AI Comparative Study of Univariate and Multivariate Strategy for Short-Term Forecasting of Heat Demand Density : Exploring Single and Hybrid Deep Learning Models." *Energy and AI* 16(January):100343. doi: 10.1016/j.egyai.2024.100343.

Sohrabpour, Vahid, Pejvak Oghazi, Reza Toorajipour, and Ali Nazarpour. 2021. "Technological Forecasting & Social Change Export Sales Forecasting Using Artificial Intelligence." *Technological Forecasting & Social Change* 163(November 2020):120480. doi: 10.1016/j.techfore.2020.120480.

Tadayonrad, Yasin, and Alassane Balle Ndiaye. 2023. "A New Key Performance Indicator Model for Demand Forecasting in Inventory Management Considering Supply Chain Reliability and Seasonality." *Supply Chain Analytics* 3(July):100026. doi: 10.1016/j.sca.2023.100026.

Wang, Chaojie, Yuanyuan Chen, Shuqi Zhang, and Qiuhui Zhang. 2022. "Stock Market Index Prediction Using Deep Transformer Model." 208(July).

Wang, Na, and Xianglian Zhao. 2023. "Enformer : Encoder-Based Sparse Periodic Self-Attention Time-Series Forecasting." *IEEE Access* 11(September):112004–14. doi: 10.1109/ACCESS.2023.3322957.

Wei, Dedai, Zimo Wang, Minyu Qiu, Juntao Yu, Jiaquan Yu, Yurun Jin, and Xinye Sha. 2025. "Multiple Objectives Escaping Bird Search Optimization and Its Application in Stock Market Prediction Based on Transformer Model." 1–51.

Zeng, Ailing, Muxi Chen, Lei Zhang, and Qiang Xu. 2017. "Are Transformers Effective for Time Series Forecasting ?"

Zhao, Zezheng, Chunqiu Xia, Lian Chi, Xiaomin Chang, Wei Li, Ting Yang, and Albert Y. Zomaya. n.d. "Short-Term Load Forecasting Based on the Transformer Model."

Zuo, Simiao, Haoming Jiang, Zichong Li, Tuo Zhao, and Hongyuan Zha. 2020. "Transformer Hawkes Process."

LAMPIRAN

Lampiran 1 Kartu Asistensi

11/08/26, 13:08

UNIVERSITAS MERCU BUANA
TERAKREDITASI UNGGUL

KARTU ASISTENSI TUGAS PROPOSAL

NAMA	:	DYAH AYU GOLDY CAHYASTUTI	**SEM/THN AKAD**	:	7 / 2026
NIM	:	41522120005	**JENIS BIMBINGAN**	:	PROPOSAL
FAKULTAS	:	FAKULTAS ILMU KOMPUTER	**DOSEN PEMBIMBING**	:	Dr. Hadi Santoso S.Kom, M.Kom
PROGRAM STUDI	:	TEKNIK INFORMATIKA			
JUDUL TUGAS AKHIR	:	ANALISIS KOMPARATIF MODEL TRANSFORMER UNTUK PREDIKSI PENJUALAN EKSPOR MULTIVARIAT DENGAN STUDI KASUS DATA SAP PERUSAHAAN XYZ			

NO.	TANGGAL	KETERANGAN	PARAF	NO.	TANGGAL	KETERANGAN	PARAF
1	09 Mei 2026	Menentukan topik penelitian dan algoritma yang akan di gunakan					
2	04 Jun 2026	Pengajuan Draft Seminar Proposal Bab 1 & Bab 2					
3	06 Jun 2026	Progres Acuan Jurnal dan kelengkapan Dataset					
4	30 Jul 2026	Pengajuan dan perbaikan bab 1&2					
5	05 Agt 2026	Pengajuan final bab 1-3					